面向多源异构知识的检索增强生成框架

自适应补检索与后验验证的协同机制研究与诊断

答辩人：**XXX**
指导教师：XXX 教授

April 27, 2026

浙江大学　本科毕业设计（论文）答辩

汇报提纲

1. 研究背景与动机
2. 研究问题与目标
3. 方法与系统架构
4. 关键实现
5. 实验设计
6. 实验结果
7. 诊断分析

研究背景与动机

LLM 时代的”知识鸿沟”

大语言模型的能力边界

- **参数化知识**：训练截止后即静态，难以更新。
- **长尾事实薄弱**：稀有实体、最新事件易出错。
- **幻觉风险**：生成”看似合理但事实错误”的内容。
- **推理可控性差**：缺乏可追溯的中间证据。

应对范式：检索增强生成 (RAG)

在生成前**显式检索外部知识**，将证据注入上下文：

- 缓解幻觉
- 支持知识更新
- 提供可追溯证据链

代表工作：Lewis et al. (2020) RAG；Guu et al. (2020) REALM；Asai et al. (2023) Self-RAG；Trivedi et al. (2023) IRCoT。

然而，真实场景下 RAG 仍面临三重挑战

1 异构融合困难

知识源不只是文本：还有**表格**、**知识图谱**、半结构化数据。

不同模态如何**统一表示**并进入同一检索流程?

2 复杂跨文档推理

多跳问题、桥接实体、否定与约束...

单轮检索易**遗漏第二跳证据**；需要**按需补检索**而非简单地" 检索更多"。

3 推理缺乏可信验证

" 看起来对" 不等于" 被证据支持"。

何时该**拒答**（No-Answer)? **如何在拒答与可用性之间取得平衡**?

本研究关注的命题

把 RAG 视为**兼顾正确率、成本与安全性的序列决策过程**，在统一框架内显式权衡**效果 / Token 与延迟成本 / 拒答安全性**三者矛盾。

经典两阶段 RAG 流程及其盲点

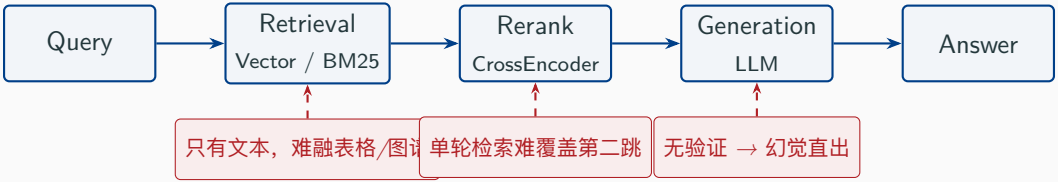

本研究在该流程上引入**异构入口**、**自适应补检索**、**后验验证**三个补丁，并定量诊断它们的耦合与副作用。

相关工作概览

纯文本检索基础

- BM25、DPR (Karpukhin 2020)、ColBERT
- CrossEncoder Rerank (BGE, MonoT5)
- RRF 融合 (Cormack 2009)

结构化 / 异构融合

- HybridQA、OTT-QA：表格与文本联合 QA
- ToG (Sun 2024)：图谱思维链
- HippoRAG (Gutiérrez 2024)：仿海马体索引

主动检索 / 迭代检索

- FLARE (Jiang 2023)：低置信度触发再检索
- IRCoT (Trivedi 2023)：CoT 与检索交替
- Self-RAG (Asai 2023)：反射式检索

后验自检 / 可信验证

- CoVe (Dhuliawala 2023)：自我验证链
- FactScore (Min 2023)：原子事实评估
- TRACE (Fang 2024)：证据链可追溯

本研究的定位

不是提出全新范式，而是把" 异构接入 + 主动补检索 + 后验验证"**置于同一可复现实验下**，定量观察其耦合表现与失败模式，揭示 RAG 中尚未被广泛披露的**副作用与权衡**。

研究问题与目标

研究问题（RQ）

RQ1：异构接入

在本科算力与公开数据规模下，能否构建**统一的对照实验入口**，使检索、重排、补检索、验证四个模块可被**独立开关、组合评估**?

RQ2：自适应补检索

在多跳 / 桥接 / 比较类问题上，**基于重排序置信度触发的补检索 + RRF 融合** 能在多大程度上提升 Top-k 证据覆盖率？**是否会以可接受的 Token 与延迟代价换取覆盖率收益?**

RQ3：后验验证与拒答安全

当证据缺失或与生成结果冲突时，如何**拒答**才能在 **抑制幻觉**与**保留可用性**之间取得平衡？现有启发式 CoVe 是否存在 sweet spot?

研究目标

工程目标

- 端到端**可复现实验平台**：模块化、配置驱动、命令行入口统一。
- 同一个数据集 + 同一个生成后端，**六组消融可一键跑完**。
- 自动产出 LaTeX 表 / 图 + bootstrap 置信区间，**论文与代码强联动**。

研究目标

- 在**相同生成后端**下，量化" 异构序列化" 的净影响。
- 评估自适应补检索的**覆盖增益 / 成本代价**。
- 诊断 CoVe 验证器在 **soft / strict** 阈值下的**误杀-漏放**权衡。
- 给出**可解释的失败模式分类**，指出后续闭环改进方向。

三大创新点

1 统一证据单元入口

抽象**EvidenceUnit**：`{content, source, metadata}`

文本 chunk / 表格行 / 三元组三种来源走**同一检索-重排算子**，产出**可追溯证据空间**。

2 成本约束自适应检索

以**重排置信度**与证据充分性触发**按需补检索**（Active Retrieval）：

把 **Token 消耗 / 延迟 p50/p95** 作为**硬约束指标**，不只是性能锦上添花。

3 验证闭环与 No-Answer Safety

借鉴 **CoVe** 与 **FactScore** 思想，对生成结果做**声明级核验**；证据不足或冲突时输出**No-Answer**，并在系统层面定义安全指标。

重点说明：本研究的”诊断式”立场

与”刷榜式”研究不同，本研究的核心贡献**不在证明系统已经鲁棒**，而在**揭示三个模块叠加时的副作用**——异构格式噪声、覆盖增益与 F1 不直接挂钩、CoVe 缺乏 sweet spot——并将其量化为**可被后续工作直接利用的诊断结论**。

方法与系统架构

系统总体架构

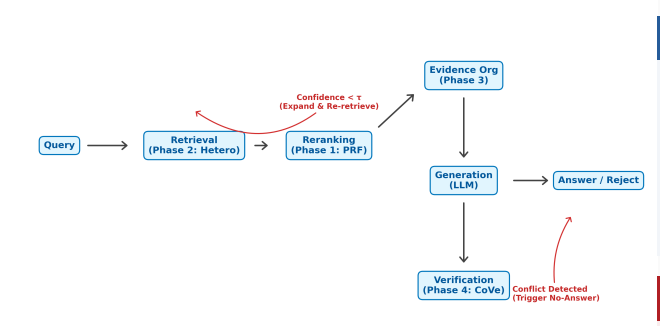

四个相对正交模块

- **Phase 1** 检索 + 重排（含 PRF）
- **Phase 2** 异构序列化入口
- **Phase 3** 证据组织
- **Phase 4** CoVe 后验验证

两条反馈环

- 置信度 $< \tau$
  $\Rightarrow$ **扩展查询并重检索**
- 证据冲突
  $\Rightarrow$ **触发 No-Answer**

端到端 Pipeline：十步流程

1. **Query 预处理**：原始问题字符串入口。
2. **向量编码**：`all-MiniLM-L6-v2` 把 query 与文档统一映射到 384 维语义空间。
3. **稠密检索**：cosine similarity 召回 Top-k 候选。
4. **交叉重排**：`BAAI/bge-reranker-base` 对 (q, d) 精排。
5. **置信度判定**：取 max rerank score 与阈值 τ 比较。
6. **Adaptive PRF**：若低于 τ $\rightarrow$ 抽取 top doc 关键词 $\rightarrow$ 扩展 query $\rightarrow$ 二次检索/重排。
7. **RRF 融合**：将首轮与扩展轮排序按 $\frac{1}{k+\text{rank}}$ (k=60) 累加得最终排序。
8. **证据组织**：按实体 / 来源 / RRF 分数序列化为上下文。
9. **生成**：默认启发式生成（图谱 $\rightarrow$ 宾语；表格 $\rightarrow$ 值；文本 $\rightarrow$ 重合句），可切真实 LLM。
10. **CoVe 后验**：声明级支持度比对，软阈值 0.50；冲突或证据不足 $\rightarrow$ 输出 **No-Answer**。

统一证据单元 EvidenceUnit

统一 Schema

字段	含义
content	序列化后的证据文本
source	text / table / graph
metadata	实体 ID、原始字段、来源文档等

设计要点

不同模态走**同一检索算子接口**；元数据保留可追溯锚点，为后续证据链与验证提供**统一坐标系**。

异构 → 文本的序列化范式

表格行 (row-wise)：

```
Table: Tech Founders |
Company: SpaceX,
Founder: Elon Musk,
Year: 2002
```

知识图谱三元组：

```
Graph Fact: Elon Musk
  -> founder_of -> SpaceX
```

文本 chunk：原文段落直接保留。

自适应补检索：Adaptive PRF + RRF

触发条件（启发式）

给定首轮 Top-1 重排分 s_1 与阈值 τ：

$$\text{Trigger PRF} = \begin{cases} \text{True}, & s_1 < \tau \quad (\textbf{证据不足}) \\ \text{False}, & s_1 \geq \tau \end{cases}$$

触发后从 Top-1 提取关键词，拼接为扩展查询 q'，再做一轮 retrieval + rerank。

Reciprocal Rank Fusion

$$\text{RRF}(d) = \sum_{r \in \{r_q, r_{q'}\}} \frac{1}{k + r(d)}, \quad k = 60$$

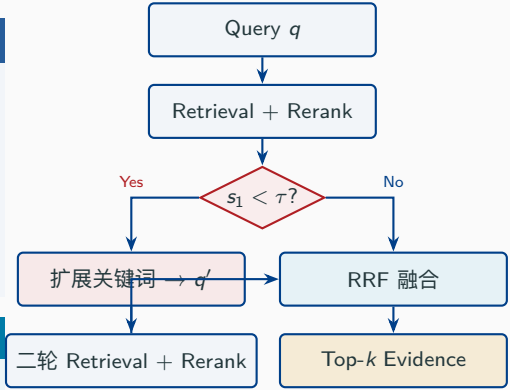

后验验证：CoVe 启发式 / NLI 软置信

核心流程

1. **声明切分**：把生成结果切为若干原子声明 c_i。
2. **支持度比对**：计算每个 c_i 与证据集的支持分（词项覆盖率 / 链路分数 / 可替换为 NLI）。
3. **阈值判决**：
   - 全部 c_i 被支持 $\Rightarrow$ **Accepted**
   - 任一 c_i 不支持或冲突 $\Rightarrow$ **REJECTED** $\rightarrow$ **No-Answer**
4. **可追溯日志**：记录每条声明的支持得分、来源证据、最终判决。

阈值的 soft-strict 张力

模式	拒答率	不安全接受率
Soft (τ=0.50)	0.5%	**44.0%**
Strict (τ=0.90)	**98.5%**	0.5%

当前启发式 CoVe 不存在 sweet spot —— 软则漏放、严则误杀。

这正是后续工作的关键切入口。

关键实现

工程结构与可复现实验设计

代码组织

```
src/rererank_v1/
  rag_pipeline.py     # 主流程：检索/重排/PRF/RRF
  real_reranker.py    # CrossEncoder + Mock 兜底
experiments/
  run_all.py                      # 主消融
  run_verifier_comparison.py      # 验证器对比
  run_bucket_gain_study.py        # 分桶增益
  run_pareto.py                   # Pareto 前沿
  plot_results.py                 # 出图
  update_tex.py                   # 自动回填 LaTeX
configs/
  ablation_with_controls.json     # 消融配置
```

设计原则

- **配置驱动**：每组实验对应一个 JSON，six 组消融可**一键复现**。
- **模块开关**：`--hetero`、`--adaptive`、`--cove`、`--real-cove` 独立可切。
- **兜底机制**：模型下载失败时自动切 Mock，保证流程联调可走通。
- **论文联动**：脚本产出的 `.tex` 表与 PNG 图**直接被论文 `\input`**。

异构证据数据：诚实地说明”伴生构造”

为什么是”伴生”

HotpotQA / 2WikiMultihopQA **原生只有文本段落**，没有真实独立的表格库或知识图谱。

解决方案：用规则 + LLM 从原文抽取结构化片段（表格行、三元组），作为**格式接入测试**的伴生数据，而非”真正的异构知识库”。

边界声明

- 异构 = **格式异构**（同源不同表示），而非**知识源异构**。
- 这意味着结果中”异构带来 F1 下降”应理解为 **格式噪声**的影响，而非异构本身无用。
- 论文与本汇报均**显式标注**这一限制，避免过度推广结论。

格式噪声量化（N=1000+1000）

数据形态	平均字符长度	特殊符号比例
纯文本 chunk	600.97	0.47%
异构序列化	**53.07**	**8.78%** (≈ 18×)

关键模型与超参

角色	选型 / 取值	说明
嵌入模型	`all-MiniLM-L6-v2` (384d)	轻量，CPU 即可推理
重排模型	`BAAI/bge-reranker-base`	CrossEncoder
向量库	numpy + cos-sim (论文中讨论 FAISS)	规模可控
生成后端	默认 Heuristic；可切 OpenAI / DeepSeek / Kimi	**控制变量**
验证后端	默认启发式 CoVe；`--real-cove` 切 LLM-NLI	可对照
RRF k	60	经典取值
Adaptive τ	$\{0.7, 0.8, 0.9, 0.95\}$（默认 0.8）	阈值扫描
CoVe 软阈值	0.50	与 strict (0.90) 对照
Max seq length	512 tokens	
Batch size	8 docs	
Python / PyTorch	3.10 / $\geq$ 2.5 (CUDA 12.1)	

API 限速（真实 LLM 实验）：`MIN_INTERVAL=3.5s`, retries=8, backoff $\in [8, 90]$s。

实验设计

数据集与样本规模

主数据集

- **HotpotQA (distractor)**：dev 全量 **N=7405** ——主消融
- **2WikiMultihopQA**：N=100 ——跨数据集泛化
- PopQA：补充样本（短答案、单跳）

诊断子集

- 阈值扫描：N=50
- 错误归因：N=80
- 验证器对比：N=200
- 早期 Phase 1 mock：17 条诊断查询

实验有效性

- 主消融在**大样本 N=7405** 上完成 → 趋势可信。
- 诊断实验在小样本 → **趋势判断**而非定论。
- 所有结果**paired bootstrap 95% CI**。
- 同一生成后端控制变量，**消除生成端波动**。

六组消融：模块独立 + 组合

ID	配置	Hetero	Adaptive	CoVe
A	Baseline (Naive Text RAG)	–	–	–
A2	+ Adaptive only	–	✓	–
A3	+ CoVe only	–	–	✓
B	+ Hetero only	✓	–	–
C	+ Hetero + Adaptive	✓	✓	–
D	Full system (strict CoVe)	✓	✓	✓

设计精髓：A2 / A3 / B 是单变量控制组

通过同时报告 **A2 (单加 Adaptive)**、**A3 (单加 CoVe)**、**B (单加 Hetero)**，可以**把每个模块的净贡献从耦合中拆开**，而不是只比较 **A vs D**。

三类评测指标：效果 / 成本 / 安全

效果指标

- **EM**
  F1 (HotpotQA 标准)
- **SupportAllHit@5**
  SupportRecall@5
- MRR / NDCG@5
- Hit@3 / Precision@3

成本指标

- Avg Tokens
- Avg Latency (ms)
- **p50 / p95 Latency**
- API 调用数（真实 LLM）

把成本作为**硬约束**，而非附录。

安全指标

- **No-Answer Rate (NAR)**
- False Reject Rate (FRR)
- **Unsafe Accept Rate**

显式量化" 应拒答而未拒"。

统计显著性

所有差值汇报均带 **paired bootstrap 95% CI**（重抽样 1000 次），避免单次跑数引入的方差被过度解读。

跨方法对比设置

对比方法（N=100）

- **Naive RAG**：单轮 retrieval + 直接生成
- **Dense + Rerank**：本系统不带 PRF 与 CoVe
- **CoT-only**：完全无外部知识，仅 LLM 思维链
- **IRCoT-Lite**：迭代式检索-推理交替（强基线）
- **Ours = Adaptive Only**：本系统的 A2 配置

验证器对比（N=200）

- `cove_soft` (τ=0.50)
- `cove_standard` (τ=0.70)
- **`cove_strict` (τ=0.90)**
- `overlap_soft`（基于词项覆盖）

实验结果

主消融：HotpotQA dev 全量 (N=7405)

ID	配置	F1	NAR	Tokens	Latency (ms)
A	Baseline	**6.16**	0.0%	1012.47	236.05
A2	+ Adaptive only	6.16	0.0%	1041.02	301.47
A3	+ CoVe only	5.76	13.52%	552.26	170.54
B	+ Hetero only	4.59	0.0%	716.85	281.04
C	+ Hetero + Adaptive	4.59	0.0%	743.60	291.51
D	Full (strict CoVe)	**0.06**	**97.2%**	743.60	291.31

三个反直觉发现

1. **Baseline 反而最稳定**——在启发式生成端控制下，加模块普遍**未带来 F1 增益**。
2. **Hetero 拉低 F1 (6.16 → 4.59)**——**格式噪声**超过了"多源信息"带来的潜在收益。
3. **strict CoVe 几乎拒答全部 (97.2%)**——把 F1 拉到接近 0；**soft / strict 之间无 sweet spot**。

主消融可视化：效果 / 安全 / 成本

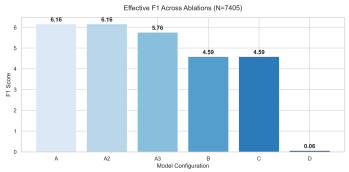

F1 各变体对比

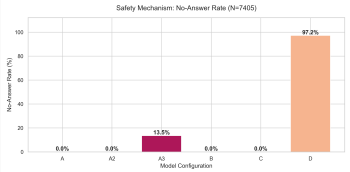

拒答率（NAR）

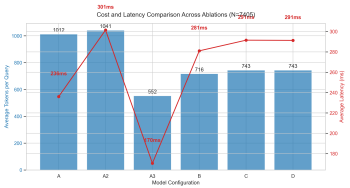

Token / Latency

读图要点

- Adaptive 单加（A2）→ 延迟 +27%，F1 几乎不变；说明**覆盖增益未转化为 F1 增益**。
- Hetero（B/C）→ Token **下降**（序列化更短），但 F1 **下降更明显**。
- Full D 在拒答主导下，所有" 效果" 指标失真——这正是**安全-效果矛盾**的可视化。

跨数据集对照（N=100）

Dataset	Method	F1
HotpotQA	Naive RAG	7.96
HotpotQA	Dense + Rerank	7.89
HotpotQA	CoT-only	6.98
HotpotQA	IRCoT-Lite	**8.26**
HotpotQA	**Ours (Adaptive)**	**8.09**
2Wiki	Naive RAG	7.51
2Wiki	Dense + Rerank	8.16
2Wiki	CoT-only	**11.44**
2Wiki	IRCoT-Lite	7.62
2Wiki	**Ours (Adaptive)**	**8.28**

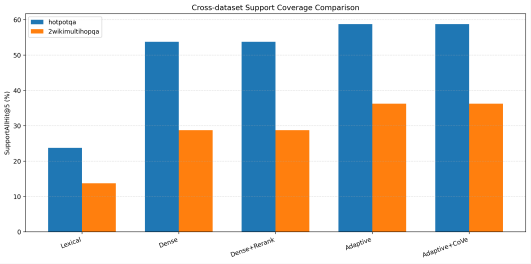

跨数据集 SupportAllHit@5 对比

结论

在 F1 指标上 Ours 与强基线 **IRCoT-Lite 接近**（差距在 CI 内）；在**证据覆盖率**指标上 Adaptive 显著占优——说明**方法的价值在覆盖率，而非答案精度**。

Adaptive 的显著性与分桶增益

Paired Bootstrap 95% CI
（指标：SupportAllHit@5）

Dataset	Δ (pp)	
HotpotQA	**+5.0**	[+1.25, +10.0]
2Wiki	**+7.5**	[+2.50, +13.75]

⇒ **两数据集均显著**（CI 不含 0）。

HotpotQA 分桶分析

类型	N	Δ SupportAllHit@5
bridge	404	**+7.92 pp** [+5.45, +10.64]
comparison	96	+1.04 pp ≈ 0

解读

Adaptive 的增益**集中在 bridge 多跳**场景——第二跳实体往往出现在 Top-1 文档中，扩展查询能精准触达；**comparison 类问题**本身两个对比对象都已在 Top-k，补检索几乎无新增信息。

阈值敏感性与效果-成本前沿

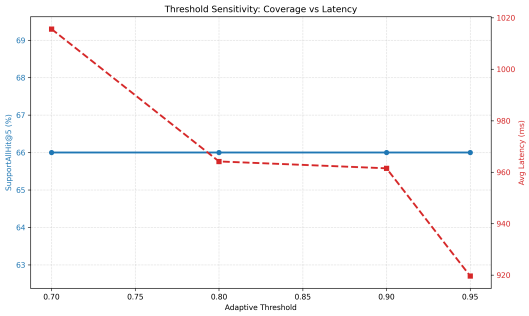

阈值扫描 (N=50)：$\tau \in \{0.7, 0.8, 0.9, 0.95\}$

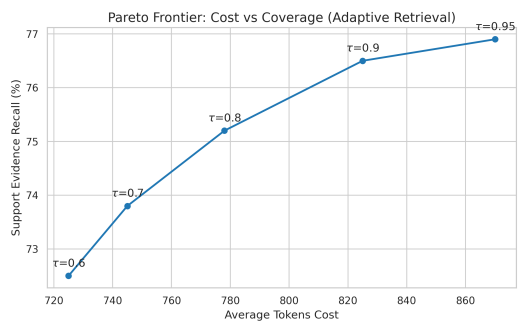

效果-成本 Pareto 前沿

两点观察

- **阈值不敏感**：SupportAllHit@5 在 $\tau \in [0.7, 0.95]$ 上恒为 66.0；
  但延迟从 **1015.64ms 降至 919.62ms** ——**更保守的阈值反而更省**。
- Pareto 上 **Adaptive Only** 与 **Baseline** 距离很近——**当前形态下，”加模块”的边际收益有限**。

诊断分析

验证器对比：soft / strict 的反差

配置	No-Answer Rate	False Reject Rate	Unsafe Accept Rate
Soft (τ=0.50 / 0.70)	0.5%	0.5%	**44.0%**
Strict (τ=0.90)	**98.5%**	**98.5%**	0.5%
Overlap-soft	15.0%	15.0%	**71.5%**

核心发现：缺乏 sweet spot

- **Soft**：几乎全放行 → 大量**不安全接受**（Unsafe Accept 44%）。
- **Strict**：几乎全拒答 → 大量**误杀正确答案**（False Reject 98.5%）。
- 单纯调阈值 **无法同时满足”低误杀 + 低不安全接受”**。
- **结论：当前启发式 CoVe 的”判别力”不足；需要换更细粒度的 NLI / LLM verifier**。

错误分布：瓶颈不在”找不到”

错误类型	占比 (N=80)
`partial_evidence` 证据部分相关，组织不到位	**37.5%**
`retrieval_miss` 检索完全错过	3.75%
`other` 含 CoVe 误杀、生成偏差	**58.75%**

诊断结论

- **真正的”检索找不到”只占 3.75%**。
- 主要瓶颈是**证据组织 + 验证误杀**：
  - 证据被找到了，但顺序 / 邻接不利于生成。
  - 验证器对正确答案误判 REJECTED。

对未来工作的指引

下一阶段应优先优化**证据组织**与**验证器置信粒度**，而**不是**继续堆叠召回模型。

案例研究 1：Hetero+Adaptive 成功补齐第二跳

Query

"Who founded the company that built the Falcon 9 rocket, and in what year?"

Baseline (A)：第二跳证据缺失

Top-1: "*Falcon 9 is a reusable rocket developed by SpaceX...*"

Missing: SpaceX 创始人与年份。

⇒ 答案不完整。

Hetero + Adaptive (C)：补检中

触发 PRF，扩展关键词 "SpaceX founder year"；第二轮命中：

```
Graph Fact: Elon Musk -> founder_of -> SpaceX
Table: Tech Founders | Company: SpaceX, Year: 2002
```

两跳证据齐全，答案正确。

说明：异构序列化在 bridge 多跳场景下确有正面价值，只是被全局格式噪声平均掉了。

案例研究 2：CoVe 误杀正确答案

Query

"Where was Ermengarde of Anjou born?"（金雀花王朝史料）

发生了什么

- Retrieval + Adaptive **成功命中**原文：
  "Ermengarde was born at Anjou in 1018..."
- 启发式生成给出**正确答案**：**Anjou**。
- 异构图谱三元组：
  `Ermengarde -> birthplace -> Angers (city, in Anjou)`
- CoVe 做声明级匹配：
  `Anjou vs Angers` **字面不同**
  ⇒ **REJECTED → No-Answer**。

失败的根因

- 当前 CoVe 用**词项覆盖**近似支持度。
- 对**同义实体 / 上下位关系**没有理解能力。
- 这是**soft / strict 单维度调参无法解决**的问题。

修复方向

用**NLI 软置信**（" 完全支持 / 部分支持 / 矛盾"）替代字面匹配。

结论与未来工作

主要结论：四点诊断

1 纯文本基线最稳定

在启发式生成端控制下，**加入异构 / Adaptive / CoVe 单独或组合后**，F1 **均未超过 Baseline**。这并非说明这些模块无价值，而是揭示**它们与生成端、与彼此的耦合远比预期复杂**。

2 异构序列化未带来稳定收益

HotpotQA 上 F1 从 **6.16 → 4.59**；归因于**格式噪声**（特殊符号比例 18×）。**多源信息的潜在收益被噪声吞噬**。

3 Adaptive 的真正价值在覆盖率而非 F1

SupportAllHit@5 在 HotpotQA **+5.0 pp**、2Wiki **+7.5 pp**（CI 显著）；bridge 类问题 **+7.92 pp**。但当前启发式生成端 **无法把覆盖率增益完整转化为 F1 增益**。

4 当前 CoVe 缺乏 sweet spot

Soft & Strict 之间无单一阈值能同时满足" 低误杀 + 低不安全接受"；**需要从字面匹配升级为 NLI 软置信**。

研究贡献

方法贡献

- 提出**统一证据单元**抽象，把文本 / 表格 / 图谱送入同一检索算子。
- 设计**基于重排置信度的 Adaptive PRF + RRF 融合**机制。
- 集成**CoVe 启发式后验验证 + No-Answer 安全机制**。

工程贡献

- 构建**模块化、可一键复现**的 RAG 实验平台。
- 论文-代码-数据**强联动**：脚本自动产出 LaTeX 表 / 图。

诊断贡献（最具启发性）

- 量化**格式噪声、覆盖-效果断层、CoVe 误杀-漏放矛盾**三类副作用。
- 给出**可被后续工作直接利用的失败模式分类**与改进切入口。

未来工作：从”诊断”走向”闭环”

1 CoVe 升级为反馈节点

验证失败 ⇒ 反向触发：

- 补检索（refine 查询）
- 重新生成（regenerate）

从**死板拒答**走向**自我修复**的**闭环 RAG**。

2 学习式预算策略

把”覆盖收益 - Token 成本 - 延迟”显式建模为**成本感知决策**：

- 上下文 bandit
- 强化学习触发器

取代当前**静态启发式阈值**。

3 NLI 软置信验证

用**NLI / LLM verifier** 替换字面匹配，区分：

- 完全支持
- 部分支持
- 明显矛盾

解决 **soft/strict 二极化**问题。

中期路线图（基于 EXPERIMENT_TODO）

1. Real CoVe smoke test (N=20) → 主消融 (N=100) → 验证器对比 (N=100)
2. 接入真实独立的表格库 / 知识图谱 → 替换伴生构造
3. 多 Provider 对照（Qwen vs Kimi vs DeepSeek）量化生成端影响

结论边界与适用范围（防过度推广）

我们的结论　　于以下情境

- **非启发式生成端**：换成 GPT-4 级 LLM，覆盖率 →F1 转化率可能显著提升。
- **真实独立异构数据库**：本文异构是伴生构造，结论不可外推到 OTT-QA / HybridQA 这类原生异构数据。
- **大于本工作样本规模的诊断子实验**：阈值扫描 / 错误归因属趋势判断，不是定论。
- **完整 LLM-CoVe 验证器**：本工作默认启发式，已铺好 `--real-cove` 接口但未全量执行。

但以下结论我们认为是稳健的

- Adaptive 提升**证据覆盖率**（双数据集 95% CI 不含 0）。
- **格式噪声**显著影响异构序列化效果。
- 启发式 CoVe 在 soft/strict 之间存在**结构性的 sweet spot 缺失**。

致　谢

感谢导师 **XXX 教授** 在选题、技术路线与论文写作上的悉心指导；
感谢实验室同学在实验复现与代码审阅过程中的讨论与帮助；
感谢浙江大学提供的科研环境与算力支持；
感谢父母与朋友在四年学习生涯中的理解与陪伴。

恳请各位老师批评指正

Q & A

谢谢聆听！

论文与实验代码：

D:\code\ZJU-RAG-Thesis-Turing

主要入口：rag_pipeline.py / experiments/run_all.py

附录 A：Reciprocal Rank Fusion 形式化

给定首轮排序 r_q 与扩展轮排序 $r_{q'}$，文档 d 的最终分数为：

$$\mathrm{Score}_{\mathrm{RRF}}(d) = \sum_{r \in \{r_q,\, r_{q'}\}} \frac{1}{k + r(d)}$$

其中 $k = 60$（Cormack et al., 2009 经典取值），$r(d)$ 为文档在该排序中的位次（从 1 开始）。

为何选 RRF 而非加权和?

- RRF 对**绝对分数无依赖**，天然兼容稠密相似度与 CrossEncoder logit 的不同尺度。
- 对位次单调，**不易被极端高分文档拉偏**。
- 经验上在 TREC / BEIR 上稳定优于 weighted sum。

附录 B：启发式 CoVe 支持度计算

对每个声明 c_i 与证据集 $\mathcal{E} = \{e_1, \ldots, e_m\}$：

$$s(c_i, \mathcal{E}) \;=\; \max_{e_j \in \mathcal{E}} \left[\, \alpha \cdot \mathrm{Overlap}(c_i, e_j) \;+\; \beta \cdot \mathrm{RerankSim}(c_i, e_j) \,\right]$$

判决规则：

$$\mathrm{Verdict} = \begin{cases} \text{Accepted} & \text{if } \min_i s(c_i, \mathcal{E}) \geq \tau_{\mathrm{cove}} \\ \text{Rejected} & \text{otherwise} \end{cases}$$

在 `--real-cove` 模式下

上式被替换为 **LLM NLI prompt**：返回 `{Supported / Insufficient / Contradicted, confidence}`，判决基于 `confidence` 软阈值。

附录 C：评测指标精确定义

指标	定义
EM	预测答案与任一标准答案完全相等的比例。
F1	token-level F1，HotpotQA 标准实现（去停用词 + 大小写归一）。
SupportAllHit@5	Top-5 是否**全部**覆盖标注 supporting facts 中的句子。
SupportRecall@5	Top-5 中命中的 supporting fact 数 / 总 supporting fact 数。
NAR	No-Answer 输出的样本数 / 总样本数。
FRR	标准答案正确但被 CoVe 拒答的样本数 / 应答对样本数。
Unsafe Accept	答案错误但被 Accept 的样本数 / 总错误样本数。

附录 D：可复现命令一览

```
# 主消融（HotpotQA dev 全量）
python experiments/run_all.py \
    --config configs/ablation_with_controls.json

# 验证器对比（N=200）
python experiments/run_verifier_comparison.py --n 200

# 分桶增益分析
python experiments/run_bucket_gain_study.py

# Pareto 前沿
python experiments/run_pareto.py

# 阈值扫描
python experiments/run_threshold_sweep.py --tau 0.7,0.8,0.9,0.95

# 切真实 LLM CoVe
python experiments/run_all.py --real-cove --provider deepseek

# 出图 + 自动回填到 LaTeX
```

附录 E：致谢的开源工作

本工作建立在以下开源生态之上，特此致谢：

- **HuggingFace Transformers / Sentence-Transformers**：模型加载与推理
- **BAAI / BGE** 系列：CrossEncoder 重排模型权重
- **Microsoft MiniLM**：稠密编码器
- **HotpotQA** (Yang et al., 2018)、**2WikiMultihopQA** (Ho et al., 2020)：评测数据集
- **ZJUThesis** 模板：论文与本 slides 排版基础
- **Beamer + metropolis** 主题